门外谈——基于信息不对称机制的多智能体圆桌辩论系统

一、作品基本信息

项目	内容
作品名称	门外谈——基于信息不对称机制的多智能体圆桌辩论系统
作品形态	Web 应用，响应式设计，桌面端与移动端浏览器均可使用
参赛赛项	自主选题类 ·（二）移动与网络应用开发类赛项
访问地址	https://outgate.chat （免费开放，无需注册与登录）
完成人	冯思涵（哈尔滨金融学院 商务英语 2026 级本科生）
指导教师	胡芳驰（第一指导教师）、霍镜宇（第二指导教师 · 校赛联络员）
版本情况	v1 于 2026 年 8 月上线并公开推广；v2 信息不对称机制为本届新增

作品以"与多位思想者对谈、并让它们同桌交锋"为核心交互：用户在 45 位可对话人格中选 1 位单人对谈，或选 2 位以上组成圆桌辩论。界面采用纸墨红的新文化运动式视觉语言，全站中英双语。

二、需求分析与目标用户

2.1 需求起点

单模型对话有两个具体缺陷。一是**立场坍缩**：模型顺着用户既有观点展开，用户得到的是"一个平均答案"，听不到真正的反对意见。二是**多智能体趋同**：多位人格共享同一份历史，数轮之内便互相附和，收敛为没有交锋的表面共识。

本项目从第二个问题切入：其根源不在人格设定不够鲜明，而在**信息分配方式**——所有人共享同一份上下文时，个体差异只能在语气层面残留。v1 以加强人格锚定缓解该现象，v2 直接从信息层解决。

2.2 目标用户

目标用户：高校师生（通识与思政课的思辨训练与讨论素材）、内容创作者（观点碰撞与选题角度）、网络文化用户（查询陌生热梗）、中英双语用户。

共同特征是**低使用意愿成本**：不愿注册、不愿付费、多用手机浏览器。因此作品免费、无登录、移动端优先；免费通道由内置的智谱 glm-4-flash 承担，零配置可用，用户也可填入自己的 API Key 与模型名（BYOK），兼容任意 OpenAI 协议服务。

三、作品功能模块与业务流程

3.1 功能模块

模块	具体能力
人格库	45 位可对话人格，由 6 位内置与 39 位社区人格（`skills/manifest.json`）合并生成
单人对谈 / 圆桌辩论	选 1 位一对一对话；选 2 位以上按可调整的顺序轮流交锋
语气控制	随口 / 较真 / 上头三档，约束单次回复长度与论证强度
网络热梗查询	识别"XX 是什么意思 / 什么梗"类提问后自动联网检索并标注来源
创意工坊	输入含 SKILL.md 的 GitHub 仓库地址，导入为新人格
双语、流式与打断	中 / EN 切换与语言跟随；SSE 逐字输出，支持停止与插话打断；含历史记录与反馈入口

3.2 业务流程

- **公开讨论**：选人入席（1 位对谈，2 位以上圆桌）→ 调整顺序 → 提问 → 各人格按顺序流式生成，后发言者读到此前全部公开发言。
- **查梗支线**：命中热梗触发词 → 并发请求多个免费检索源 → 结果注入本轮提示词、正文前显示来源行；失败静默跳过。
- **导入支线**：粘贴 GitHub 仓库地址 → 服务端深度 1 克隆 → 校验 SKILL.md → 写入人格注册表。
- **v2 信息层流程（本届新增）**：用户对某位在座人格发送**悄悄话**，内容仅其可见；公开发言可标记**可见性**为"仅某某可见"。生成每位发言者的回复时只投喂其有权读到的历史。A 从悄悄话得知"B 不赞同你"后，会在公开发言中主动把 B 拉入讨论。每轮结束计算**信息新颖度**，判定讨论趋同时先强制提出反对意见，仍无新信息则由**主持人收尾**拆穿伪共识。

三档语气是写入系统提示词的硬约束：**随口** ≤2 句 / 60 字，**较真** ≤6 句 / 300 字，**上头**不设上限。

四、核心创新：信息不对称机制

4.1 现有同类做法及其后果

据课题组对同类公开产品与开源多智能体框架的调研，绝大多数 AI 圆桌与多智能体辩论实现遵循同一模式：**所有角色共享同一份会话上下文**。工程上这最省事，但每个角色都能读到他人的全部发言，最省力的策略便是附和、复述与折中，讨论数轮后便退化为轮流发言。

【待确认：同类产品的名称、版本与截图证据尚未固化。】

4.2 v2 的做法：给圆桌加一层信息层

v2 的核心改动是**让不同发言者掌握的上下文不再相同**，由四个机制构成（前三个构成信息层，第四个负责在讨论空转时介入）。

- **可见性**：每条发言带可见范围标记，取值为 `public` 或"仅某某可见"。生成回复时先按该发言者的权限过滤历史，只把其有权读到的部分拼入提示词。

- **悄悄话**：用户私下对某一位在座人格说话，内容不进入其他人的可见历史。被私下告知者获得独有信息，其公开发言带上其他角色无法追溯的依据。用户由此从"提问者"变为"信息的分配者"。
- **点名拉人对峙**：前两个机制的涌现结果。A 会在公开发言中主动把 B 拉进讨论并要求其表态，讨论因此从轮流陈述变为带有暗流的博弈：某些冲突的起因只有用户与当事角色知道，其余角色只能从公开信息中推断。被点名者会收到"不许用『我同意』开场"的约束，避免冲突被客套消解。
- **讨论停滞判据与主持人收尾**：把每轮发言切成字符 2-gram，与此前全部内容比较"不重叠率"作为该轮的信息新颖度（纯本地计算，不额外调用模型）。新颖度低于阈值即判定讨论在互相附和，此时先向所有发言者注入"必须提出反对意见或新角度"的指令；若一轮试过仍未产生新信息，则由「门外谈」本人（不属于桌上任何立场）出面收尾，直接指出表面共识为何是空的、真正的分歧在哪、哪个问题始终无人回答。

4.3 与现有产品的差异对比

对比维度	常见 AI 圆桌 / 多智能体产品	门外谈 v2
上下文分配	全员共享同一份上下文	按发言者过滤，各人可见历史不同
用户角色	公开发问者	公开提问者 + 私下信息分配者
讨论走向	数轮内趋同，形成表面共识	出现立场迁移、点名对峙与信息优势
冲突来源	人格设定的语气差异	人格差异 + 真实的信息差

4.4 为什么是实质性改进而非功能堆叠

信息不对称改变的是系统的**信息结构**：原本单一的上下文管道要变成"按接收者筛选"的管道。它把讨论从角色扮演式的轮流发言，推向每个参与者基于不同信息独立判断——人类圆桌的张力恰恰来自"我知道一些你不知道的事"。

【实现状态：v2 四个机制已在开发分支 `cmit-2026` 完成编码（提交 `0bc0458` → `969d97e`），并通过 `tsc --noEmit` 与 `next build` 验证；接口与前端入口均已接通，已在浏览器中完成端到端实测。上线状态见第八章。】

五、技术路线与系统架构

5.1 技术选型

- **前端**：Next.js 16.3.1（App Router）+ React 19.2.8，TypeScript 5.9 全量类型约束；
- **样式与动效**：Tailwind CSS v4 承担布局与主题，GSAP 与 ogl / three.js 承担背景与滚动动效；
- **模型接入**：OpenAI 兼容 SDK，服务端通过 `AI_API_KEY`、`AI_BASE_URL`、`AI_MODEL` 配置，默认智谱 glm-4-flash；
- **人格注册表**：`lib/skills.ts` 读取 `skills/` 与 `skills/manifest.json`，负责元信息、提示词拼装与导入写入；
- **部署**：阿里云香港服务器，podman 容器运行 Node 20 生产镜像。

【待确认：仓库 Dockerfile 基础镜像为 `node:20-alpine`，历史交接文档记载早期部署在 Sealos；本处按"阿里云香港 + podman"表述，提交前以线上环境截图为准。】

5.2 请求链路

浏览器把人格 ID、会话历史、语气档位、语言与 BYOK 配置提交至 `/api/chat`；服务端按人格 ID 取出元信息与 SKILL.md，拼装系统提示词（人格设定 + 平台规则 + 语言规则 + 本轮语气约束 + 对话纪律条款）；命中热梗触发词时先做多源并发检索并注入摘要。随后按顺序逐位请求模型，以 ReadableStream 通过 `text/event-stream` 逐块下发，前端增量渲染，新发言追加进历史供下一位读取。

5.3 架构图

!系统架构图

数据流向：浏览器 → Next.js 服务端（人格注册表、提示词拼装、检索）→ 模型服务 / 多源检索 → SSE 回传。

（架构图与交互流程图已生成于 `competition/diagrams/`，含 SVG 与 2× PNG，可直接插入本节。）

5.4 关键工程决策

- **语气约束前置**：长度与论证强度写入系统提示词，而非前端截断，避免"表面变短、内容仍在灌水"。
- **检索失败静默降级**：查梗链路任一环节超时或异常均不阻断主对话。
- **人格锚定条款**：提示词明确"你是你自己，不模仿、不复述其他发言者的自称与语气"，回应他人时先明确赞同或反对、再给独立理由。v1 更新记录显示该项曾用于修复 10 位人格被带偏、复读的现象。
- **强制英文兜底**：英文模式注入仅英文规则，并设字符集校验与重试。

六、交互设计

- **入席即可用**：首页直接呈现人物列表与人物志，点选头像即入席，无注册、无引导页。
- **视觉语言服务于议题**：纸墨红与印刷质感的新文化运动式设计，把"辩论"放进合适语境。
- **节奏可控**：圆桌可调整谁先开口；回复逐字流式出现，发送键三态（发言 / 停止 / 继续输入），AI 说话时可直接输入新问题插话，已生成内容保留。
- **不强制回到底部**：辩论中可自由上翻阅读历史，仅当贴近底部时才自动滚动，右下角提供"回到最新"。
- **移动端适配**：支持触屏长按调整座位，主要操作可单手持机完成。

七、数据安全与隐私保护

- **无账号、无实名**：不设注册登录，不采集姓名、手机号、邮箱等身份信息。
- **API Key 不落服务端**：用户自带的 API Key 与模型名仅存于浏览器本地存储，服务端不持久化保存、不上传第三方；站点内置通道的密钥仅存于服务器环境变量，前端不可见。

- **可见性机制本身就是隐私设计**：可见范围标记在生成层即完成过滤，不可见的历史片段不会进入对应角色的提示词；"其他角色不知道"因此是模型层面的真实不知情，而非仅在界面上隐藏。
- **检索与日志最小化**：热梗检索仅传递从问题中提取的关键词，不传递会话上下文与用户标识；会话与反馈记录以追加写落盘，不含账号关联信息；检索按用户限频（每分钟不超过 2 次）。

八、完成度与可验证性

8.1 可访问版本与功能完成度

线上地址 https://outgate.chat ，无需注册与安装，浏览器打开即可使用；旧域名自动 308 跳转，历史链接不失效。

v1 所列功能均已在线上版本可用；v2 的信息层机制为本届新增，其完成状态与演示路径见下方标记。

【待确认：v2 信息层机制的上线时间、可复现的操作路径与演示截图；提交前需在线上环境完成一次完整流程验证并截图留证。】

8.2 测试说明

- **功能测试**：按功能清单逐项执行，覆盖选人入席、单聊与圆桌、语气切换、发送 / 停止 / 插话、历史回看、语言切换与导入新人格全流程。
- **异常与中断测试**：无 API Key、Key 失效、模型超时或报错、检索源不可达；生成中点击停止，验证已生成内容固化、加载状态清除。
- **兼容性测试**：桌面端 Chrome / Safari / Edge，移动端 iOS Safari 与 Android Chrome，验证布局与滚动。

【待确认：正式测试用例表、测试记录与测试环境版本号需在交付前补充。】

8.3 演示材料与评审通道

功能演示视频与界面截图见 `competition/video/` 与 `competition/screenshots/` 。

（截图与演示视频见 `competition/screenshots/` 与 `competition/video/` 。本作品**无需登录**，评审可直接访问体验，无测试账号需求。）

九、应用推广价值

v1 已于 2026 年 8 月上线并对外公开推广，先后在 B 站、小红书、微信视频号、抖音、YouTube 五个平台各发布一条介绍视频，已获得真实用户的实际使用。

【待确认：各平台视频链接、播放与互动数据、真实用户规模尚未提供，故不列具体数字；建议提交前补充可查证的数据截图。】

价值分析：

- **教育场景可落地**：可作通识与思政课堂的思辨训练工具——无需账号、无需安装，教师可直接投屏或让学生用手机进入同一位思想家阵容。
- **信息差的可讲解性**：用户通过分配悄悄话直观体会"同一件事因信息不同而结论不同"，是可讲解的传播学与博弈论素材，也与完成人的商务英语专业背景相关。
- **内容生产与生态扩展**：圆桌交锋可作自媒体选题与文案素材；创意工坊基于 SKILL.md 导入人格，内容生态可由社区扩展。
- **零门槛与可持续**：免费无登录降低使用阻力，内置免费模型通道使作品在无商业收入时仍可长期开放。

十、原创性说明

按赛事要求，本节列明原有成果、新增内容与本届团队贡献。

10.1 原有成果（v1）

- **作品形态与功能**：门外谈 v1，AI 思想家对谈与圆桌辩论网站，纸墨红报纸风，免费、无登录。
- **技术形态**：Next.js 16 + React 19 + TypeScript + Tailwind v4，SSE 流式输出，支持 BYOK 与多模型切换，默认智谱 glm-4-flash。
- **上线与推广状态**：2026 年 8 月上线（outgate.chat），并在 B 站、小红书、微信视频号、抖音、YouTube 各发布过一条介绍视频，已有真实用户。
- **人格来源**：来自上游开源社区的蒸馏成果，作品在致谢中标注版权归原作者所有；应用自身采用 MIT 许可证。

10.2 新增内容（v2，本届参赛核心）

在 v1 的圆桌之上增加一层**信息层**，使不同发言者掌握的上下文不再相同：

1. **可见性**：每条发言具有 `public` 或"仅某某可见"的可见范围；生成回复时只向该发言者投喂其可见的历史。
2. **悄悄话**：用户可私下对某一位在座人格说话，其他在座角色看不到该内容。
3. **点名拉人对峙**：A 从悄悄话中得知"B 不赞同你"后，会主动把 B 拉进公开讨论并要求其表态。
4. **讨论停滞判据与主持人收尾**：以字符 2-gram 不重叠率衡量每轮信息新颖度，判定趋同后先强制提出反对意见，仍无新信息则由主持人收尾拆穿伪共识。

四项机制共同构成对"全员共享同一份上下文"式圆桌的实质性改进：前两项制造信息差，第三项让信息差在公开场合显形，第四项保证讨论不会以和气收场。

10.3 本届团队贡献

- 完成人为**冯思涵**，哈尔滨金融学院商务英语 2026 级本科生，**非计算机专业出身**。
- **产品设计、功能定义、界面设计、代码实现与云端部署**均由完成人独立完成；开发中借助 AI 编程工具辅助编写与调试代码，但选题判断、需求取舍与最终验收由完成人自行负责。

- v1 的**全部功能实现、上线部署与多平台推广**由完成人独立完成。
- v2 的**信息不对称机制**由完成人提出设计，包括信息层四个机制、可见性的数据结构与生成层过滤方式、讨论停滞的量化判据，以及与既有圆桌流程的整合方案。
- 参赛材料（本文档、系统说明、功能演示与界面截图）亦由完成人整理。
- 指导教师：胡芳驰、霍镜宇。

十一、后续迭代计划

1. **以新颖度作为讨论停滞判据**：目前讨论是否继续依赖轮次与用户手动结束。后续计划对每轮发言计算与既有内容的词汇重叠率或语义新颖度，连续低于阈值即判定趋同，自动提示用户更换议题、追加悄悄话或调整阵容，使"讨论是否还有价值"成为可观测指标。
2. **信息层机制完整化**：补充可见范围编辑、悄悄话历史的分角色视图，以及"信息差消退"提示（私下信息被公开披露后标记该差异已消除）。
3. **评估体系**：做小规模对照测试，在同一议题与阵容下对比两种模式的发言相似度与立场迁移次数，用可复现指标说明改进效果。
4. **人格、语言与稳定性**：扩充人格库与英文人格质量，完善导入人格的安全校验（导入内容仅作系统提示词使用）；补充错误率、首字延迟与中断成功率的线上统计。