2026 年第十四届全国大学生数字媒体科技作品及创意竞赛

门外谈

——基于信息不对称机制的多智能体圆桌辩论系统

自主选题类 · 移动与网络应用开发类赛项

团队负责人：冯思涵（哈尔滨金融学院 · 商务英语）

指导教师：胡芳驰、霍镜宇

作品网址： outgate.chat

一句话

给 AI 圆桌加一层「谁知道什么」——

让讨论从轮流发言，变成有暗流的博弈。

01 · 问题

AI 圆桌为什么总是「和和气气」？

现在几乎所有 AI 圆桌 / 多智能体产品，

都是「全员共享同一份上下文」。

后果是一个已知的病症：

所有 agent 都知道别人说了什么，

于是迅速趋同，产生伪共识。

看起来在辩论，实际在互相附和。

实测：加了「别和稀泥」也没用

用户在公开提问里明确写了

「请直接给答案，别和稀泥」——

鲁迅：学外语的意义，绝不仅仅在于翻译与写作……

乔布斯：我同意鲁迅的观点。

→ 两个立场最互斥的人，第一轮就合流了。

02 · 核心创新

加的不是功能，是一层结构

v1： 所有人共享同一份上下文

→ 每个人的「所知」完全相同

→ 讨论必然走向趋同

v2： 给圆桌加一层「信息层」

→ 每条发言可以只让某个人看到

→ 每个人看到的上下文不再相同

「谁知道什么」本身成了设计对象。

四个机制

① 可见性

发言带 public / 仅某人可见标签，

进 prompt 之前按可见集合裁剪

② 悄悄话

用户可以私下对某一位人物说话

③ 点名对质

收到悄悄话的人会当众点名对方

④ 信息新颖度

讨论空转时强制提出反对意见

03 · 机制

① 可见性　② 悄悄话



人物卡片上的「私」按钮点亮后，输入框上方出现状态条：
「正在私下对 鲁迅 说话 —— 桌上其他人看不到」



这条消息在对话流里带锁标记：
「私下说的 — 只有 鲁迅 看得到」；服务端真过滤，不是前端隐藏。

③ 点名对质　　④ 信息新颖度



唯一收到悄悄话的鲁迅，当众点名乔布斯：
「乔布斯曾言...那么我问他：改变世界之前，你改变过多少人替你抬轿子？」

④ 信息新颖度（信息熵判据）

把发言切成字符 2-gram，与此前全部内容比较
不重叠率 → 全是旧话接近 0，全是新东西接近 1
纯本地计算，零额外模型调用
低于 0.34 → 判定趋同 → 强制提出反对意见

为什么用「新颖度」而不是「聊够了」

「聊够了」是主观判断，无法量化；
「新信息不再产生」是可以计算的客观事实——
这也是一个真实多智能体工程实践里验证过的做法。

05 · 效果

同一桌人，同一议题，差别在哪

加信息层之前

鲁迅：

学外语的意义，绝不仅仅在于翻译与写作……

乔布斯：

我同意鲁迅的观点。语言确实是文化的载体……

→ 回到讲道理，互相附和

加信息层之后

鲁迅（唯一收到悄悄话）：

乔布斯曾言…那么我问他：改变世界之前，

你改变过多少人替你抬轿子？

乔布斯（被点名，不知道内情）：

你说得对，我不是一个人做成的。

但沃兹尼亚克也不是我雇来的——

他是因为看见我在做一件值得做的事才留下来的。

→ 当面对质，各自站稳

06 · 技术架构

分层架构与 v2 新增点



这一层是作品的原创技术核心

核心业务层 = 圆桌调度器

把「议题 + 人格 + 可见性规则」

编排成一轮轮交锋的 AI 发言

① 议题输入 → ② 轮次控制器

（发言顺序、点名拉人对峙）

→ ③ 发言者 prompt 组装

← 历史上下文（按可见性过滤后注入）

→ ④ 模型调用 → ⑤ 输出装配

蓝色描边为 v2 新增：

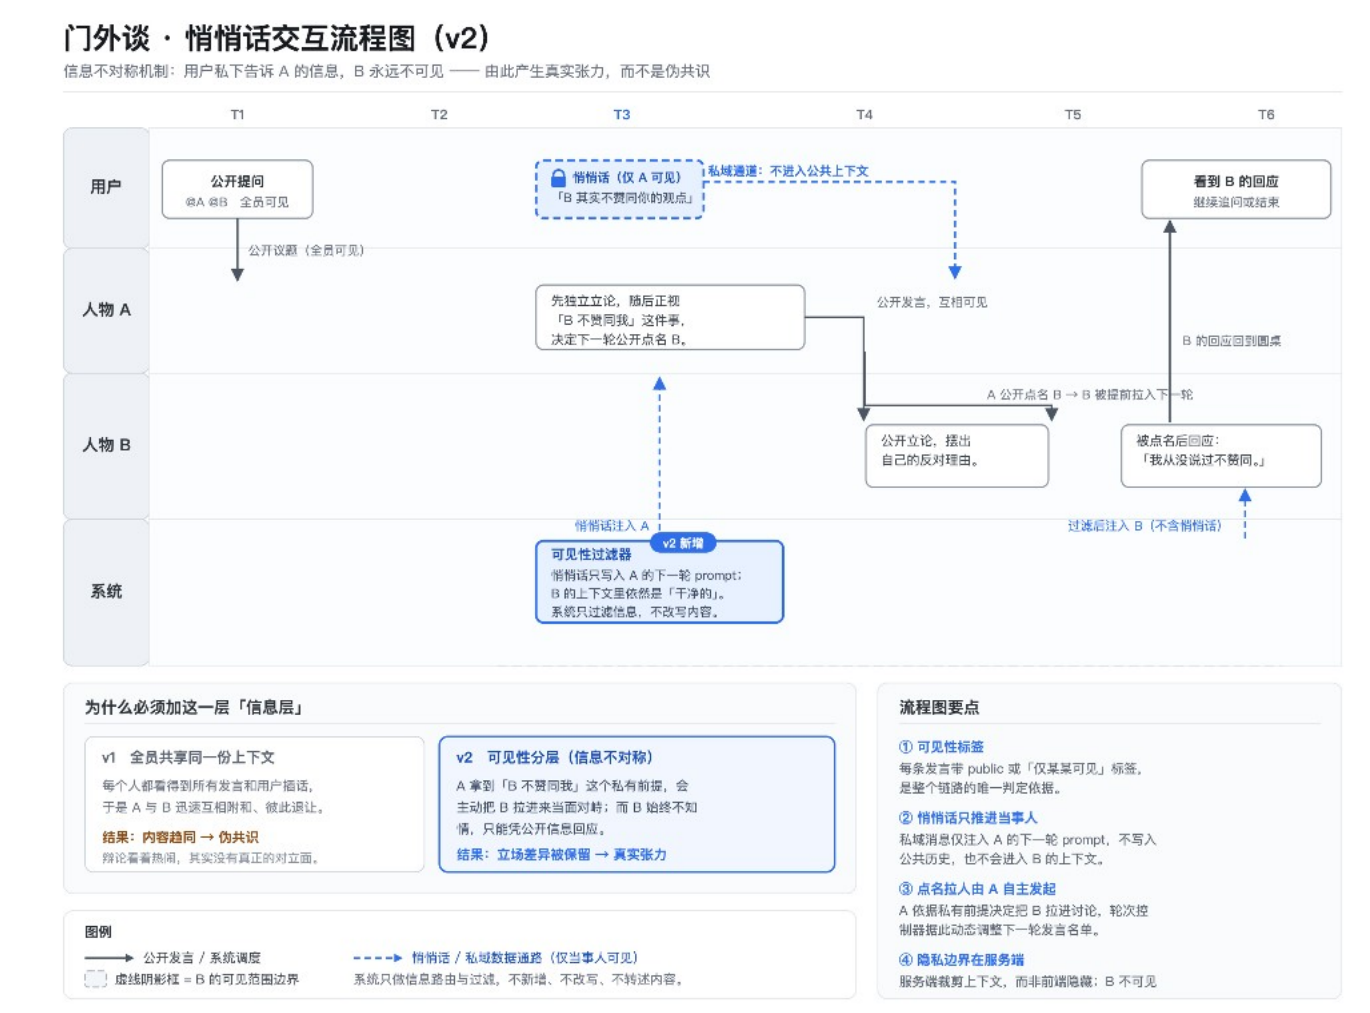
- 可见性过滤器
- 悄悄话存储器

底部四格是对「数据安全意识」

这一评审要点的正面回应。

07 · 交互流程

一次悄悄话的完整链路



一次悄悄话的六步

T1　用户公开提问

T2　A 、 B 公开发言，互相可见

T3　用户私下对 A 说：
「B 不赞同你的观点」

T4　A 主动公开点名 B

T5　系统把 B 提前拉入下一轮

T6　B 回应，讨论继续

阴影框标出的是 B 的可见范围——
从头到尾，他都不知道
用户私下跟 A 说了什么。

这就是「信息不对称」
在时序上的具体形状。

08 · 数据安全与隐私

信息层本身就是一套隐私设计

最小权限

悄悄话只进当事人 prompt；
服务端按可见集合裁剪，
不是前端隐藏，不落公共上下文

不写日志

悄悄话原文不写入 /api/log，
日志只留标记；
不用于任何训练或分析

检索隔离

查梗检索只由公开消息触发，
悄悄话内容不会被搜成
「场外情报」注入给所有人

密钥与部署

默认 Key 仅服务端；
BYOK 密钥不落库、不写日志；
HTTPS + 非特权容器

09 · 完成度与验证

全部结论来自实际运行

tsc --noEmit	退出码 0
next build	Compiled successfully， 8 个路由正常生成
T1 悄悄话定向发言	who 事件仅 1 个（当事人），其余在座者不发言
T3 摊牌机制	修复前泛泛而谈 → 修复后「乔布斯曾言...我却问你」
T4 抗伪共识	修复前「我同意鲁迅的观点」→ 修复后正面辩解
T5 新颖度判据	原文重放的历史 → value: 0, stagnant: true
R1 单人对谈回归	who 事件 1 个、 novelty 事件 0 个，单人逻辑未受影响
R2 英文模式回归	两人发言，回复汉字数量 0
R4 12 人布局回归	自动收缩为头像方片，每张卡片仍带「私」按钮

已知边界如实说明：悄悄话当前只做单目标入口；摊牌效果依赖模型配合，偶有波动；
新颖度阈值 0.34 为实测经验值；线上仍为 v1，提交前如需在线验证须先部署。

一个人，非科班，借助 AI 工具

作者：冯思涵

哈尔滨金融学院 · 商务英语专业 · 单人参赛

非计算机科班出身，独立完成：

- 产品定位与选题论证
- 信息层机制的构思与设计
- 前后端开发、调试与云端部署
- 界面与视觉语言设计
- 上线与多平台推广运营

AI 承担的是实现工作；

构思、判断、审美与验收标准由作者负责。

AI 工具使用（如实申报）

- 开发： DeepSeek Harness 等 AI 编程助手
- 运行时：智谱 GLM-4-Flash （默认） + BYOK
- 宣传视频配音： Fish Audio TTS

AI 不参与的部分

- 问题发现：为什么 AI 圆桌总是趋同
- 机制设计：可见性 / 悄悄话 / 点名对质 / 新颖度
- 一切取舍与验收标准

详见《人工智能工具使用情况说明》

从「看热闹」到「帮你想清楚」

应用价值

- 思辨训练：让用户看到「同一件事，不同立场的人会怎么拆」
- 决策辅助：把「我的智囊团」从比喻变成一个能用的东西
- 反信息茧房：用信息不对称强制保留立场差异
- 开放：人格以 SKILL.md 组织，任何人都能导入新角色

迭代计划

- 悄悄话支持同时告知多人，形成临时的「小圈子」
- 讨论停滞时引入 supervisor 收尾总结（当前只做了强制反对）
- 新颖度曲线可视化
- 多人公开房间：每个用户拥有自己的一份可见性视图