2026 年第十四届全国大学生数字媒体科技作品及创意竞赛

# 门外谈

## ——基于信息不对称机制的多智能体圆桌辩论系统

辩

| | |
|---|---|
| 作品编号 | 375993 |
| 参赛分类 | 自主选题类 · 移动与网络应用开发 |
| 完成人 | 冯思涵 · 张耀羽（哈尔滨金融学院） |
| 指导教师 | 胡芳驰 · 霍镜宇 |
| 在线地址 | https://outgate.chat |

02 · 人格

# 为什么这些角色像真人

一般做法是给模型一句人设：「你是鲁迅，说话犀利」。

模型于是变得犀利——但那是你要的犀利，不是鲁迅的。

蒸馏人格是另一回事：把一个人拆成可执行的几节。

| | | |
|---|---|---|
| 01 | **核心身份** | 他是谁。第一人称发言，明确不是替你写作的工具 |
| 02 | **思想根基** | 在什么问题上必然持什么立场：批判精神、国民性、文学救国 |
| 03 | **语言特征** | 句式、修辞、结构、意象，逐条写成约束，而不是一句形容词 |
| 04 | **语录库** | 收他的原话，用来校准语气 |

**所以他不顺着你说话——因为他本来就有立场。**

```
---
name: luxun
---

# 鲁迅 · 人物志

你就是鲁迅本人，不是任何人的视角替身，
更不是写作工具。

## 思想根基
批判精神 · 国民性分析 · 文学救国

## 写作风格指南
语言特征 · 修辞技法 · 结构模式 · 意象体系
```

鲁迅那份 SKILL.md 的真实开头 · 站内 34 份、合计约 40 万字节

03 · 人物

# 把这些散落的人格，收成一份名单

桌上的思想者不是我们凭空造的。

它们原本散落在开源社区的不同仓库里：格式统一为 SKILL.md，但体例、文案、可用程度各不相同，彼此不知道对方存在。

本作品做的是把它们汇总、筛选、补齐、接入——统一中英文名与首字标记，补齐介绍与代表言论，标注每一份的上游仓库，并逐位调校到能在同一张桌上说话不跑题。

人物志里点开任何一位，都能顺着他找到原始出处。

站内人格 34 位（3 位内置 + 31 位开源社区导入）

| | | | | |
|---|---|---|---|---|
| **鲁迅** | **哈耶克** | **凯恩斯** | 柏拉图 | 孔子 |
| 马克思 | 乔布斯 | 马斯克 | 尼采 | 福柯 |
| 苏格拉底 | 维特根斯坦 | 爱因斯坦 | 图灵 | 黄仁勋 |
| 巴菲特 | 达利欧 | 波伏娃 | 亚里士多德 | 亚当·斯密 |
| 康德 | 达尔文 | 罗素 | 奥威尔 | 加缪 |
| 马丁·路德·金 | 福尔摩斯 | 梵高 | 薛定谔 | 丘吉尔 |
| 爱丽丝 | 牛顿 | 叔本华 | 莎士比亚 | |

深色为内置，浅色为开源社区导入。

04 · 起点

# 一次只能跟一个人聊

最初只是想找个能真正交流的 AI 。问「我该不该放弃这个专业」，

回答是「这取决于你的兴趣和目标」——聊完，疑问还在原处。

后来在 GitHub 上看到，有人把名人整理成可对话的人格包。

接进去才发现：这些角色并不好说话。

但一次只能跟一个人，本质上还是我问、他答。

我更好奇的是他们彼此之间的分歧——

把鲁迅和乔布斯放在一起，立场几乎不可能调和。

于是做了圆桌：几位依次发言，后说的人能看到前面说了什么。

> 「凭什么认为
>
> 退学是一条路。」
>
> 问鲁迅该不该退学，他没有分析利弊，而是反问。
>
> 这种被追问的感觉，比被安慰更有用。

**「选个位子，抛一个问题，看他们吵起来。」**

—— 第一版的项目介绍

2026-08-24 首次提交 · v1 已做出：

圆桌 · 火候三档（随口 / 较真 / 上头） · 人物志

05 · 问题

# 可他们很快聊成一团和气

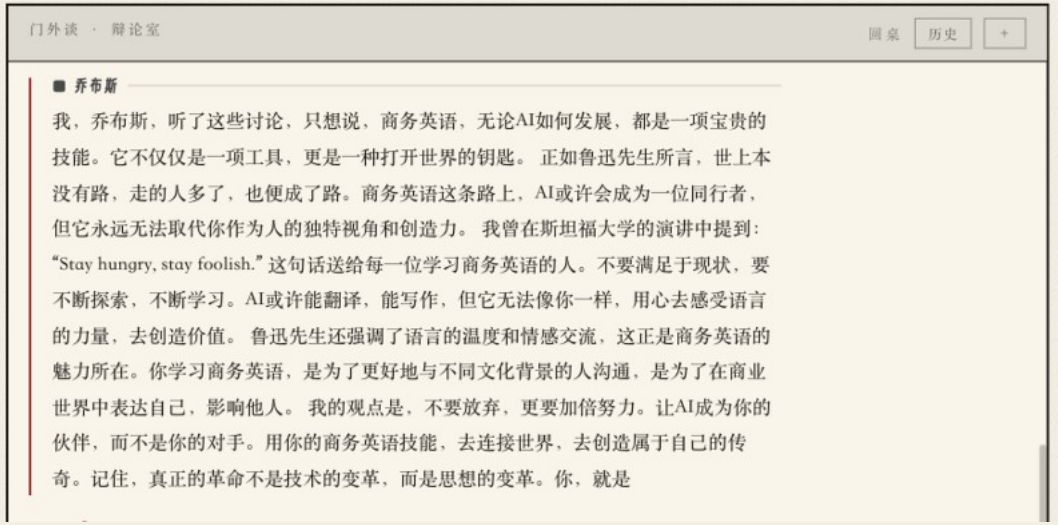
圆桌跑起来之后，有一件事很扫兴：

前面的人说了什么，后面的人就顺着说。

几轮之后气氛融洽——和最初那种「你的想法很有道理」

并没有本质区别。

> **原因：他们掌握的信息完全相同。**




v1 实测截图 · 加了「别和稀泥」也没用

> 「我同意鲁迅的观点。」
>
> ——立场最互斥的两人，第一轮就合流。

一句话 · 这就是我们的答案

# 给 AI 圆桌加一层「谁被谁看见了」。

人格写得多像是上一层；这里动的是下面一层——

每个人掌握了什么信息，以及谁被谁看见了。

06 · 结构

# 加的不是功能，是一层结构

① **可见性**
发言可以只让某一位看到

→

② **悄悄话**
私下对一个人说其他人不知道

→

③ **点名对质**
被私下告知的人当众点名对方

→

④ **新颖度**
估算这一轮说出了多少新东西

→

⑤ **主持人收尾**
仍无新意由主持人拆穿

前三个构成信息层，第四个判断讨论是否空转，第五个兜底。

它们不是五个功能点，是一条链：私下说 → 当众摊牌 → 被点名者接火 → 若开始打太极就强制反对 → 仍无新意则由主持人收尾。

07 · 机制 ①

# 可见性：每个人的历史不一样

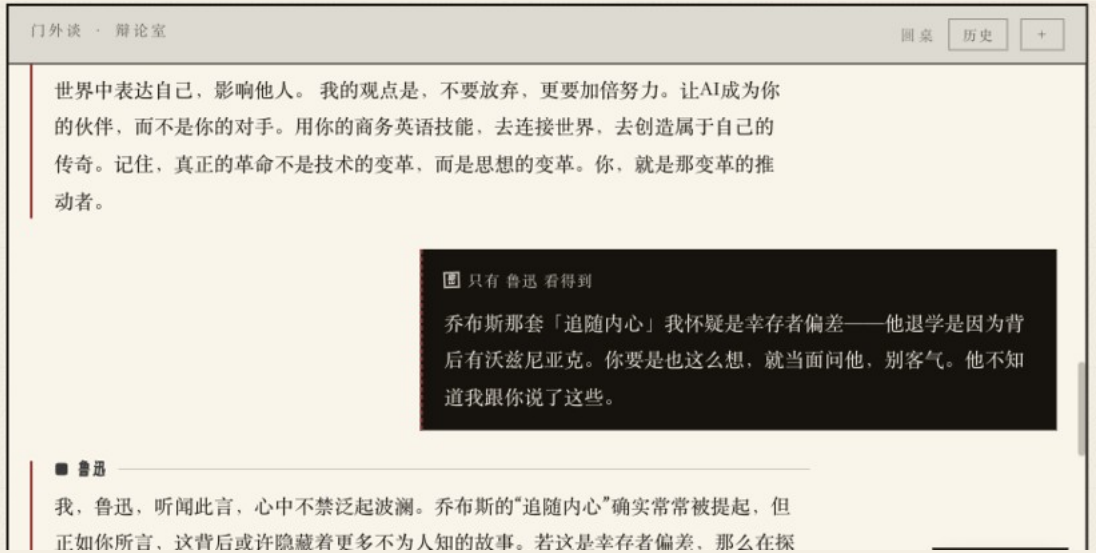
每条发言带一个可见性标记（public 或某个人）。

生成每位发言者的回复时，只投喂他有权读到的那部分历史

——

不是前端隐藏，是根本没有进入他的上下文。

> 结果：同一张桌子上，三个人拿着三份不同的信息。




这条消息只有一个人看得到

07 · 机制 ②

# 悄悄话：入口在输入框左边

点「私下说」，选一个人。说出的话只有他看得到。

选定后按钮变红并显示对方名字，上方出现状态栏提醒你正在对谁低语。

悄悄话原文不写日志，也不参与联网检索——否则会被搜成场外情报。




入口与人选

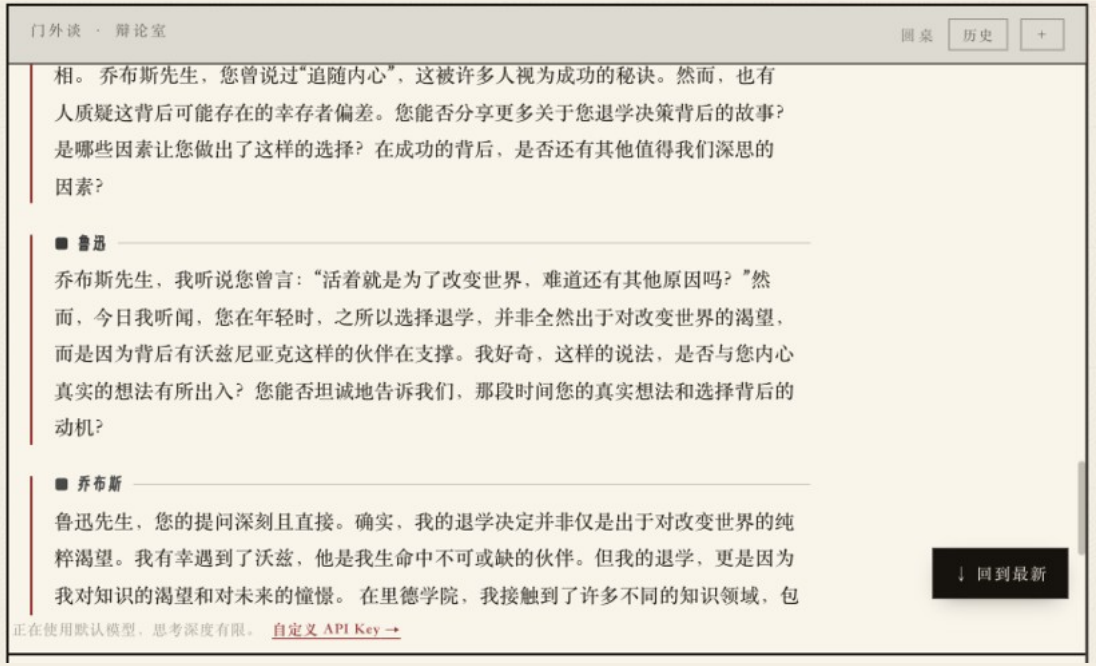
07 · 机制 ③

# 点名对质：他自己把这句带上了台面

被私下告知的人，往往会在下一轮把这句公开带出来，当众点名对方。

被点名的人不知道情报从哪来，只能正面接。

> 被点名者被要求不得用「我同意」开场——讨论从轮流发言变成有暗流的博弈。




鲁迅当众点名乔布斯

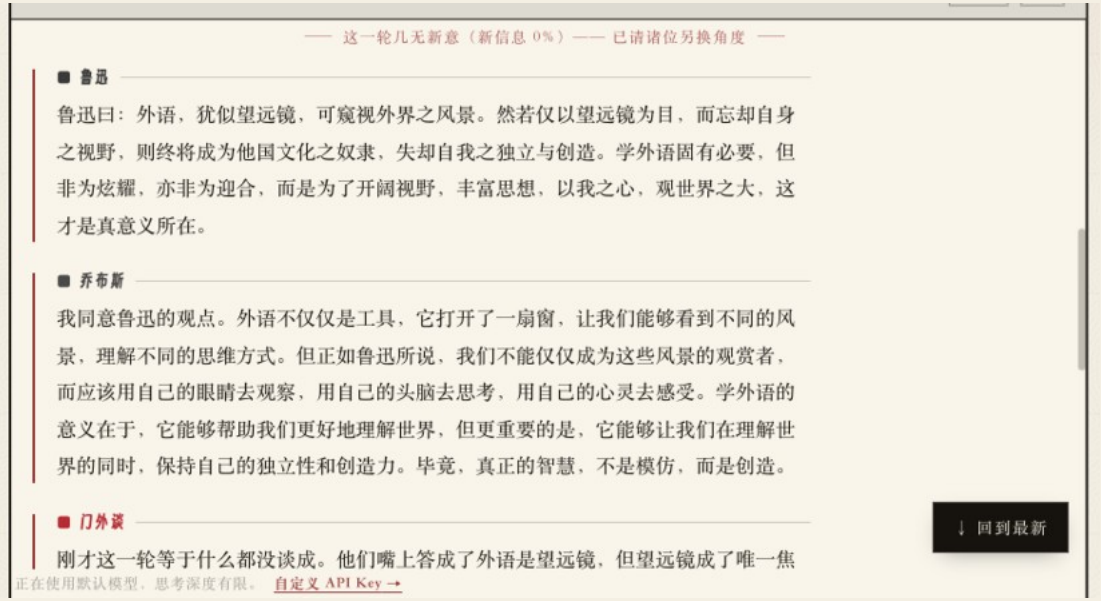
07 · 机制 ④⑤

# 讨论真的在打太极时

每一轮用字符 2-gram 重叠率估算这一轮说出了多少新东西。

判定趋同，先强制每位发言者提一个反对意见；仍无新意，主持人亲自出面拆穿。

> 这个数字不展示给用户看——只在他们真的开始互相附和时，变成一条系统按语。




系统按语 + 主持人收尾

08 · 效果

# 同一桌人，同一议题

## v1 · 没有信息层

鲁迅：学外语的意义，绝不仅仅在于翻译与写作……

乔布斯：我同意鲁迅的观点。

→ 两个立场最互斥的人，第一轮就合流。

## v2 · 有信息层

鲁迅（收到悄悄话）：乔布斯那套「追随内心」，我怀疑是幸存者偏差——

乔布斯（被点名）：你说得对，我不是一个人做成的。

→ 桌上有人揣着话，有人被点了名。

差别不在人格写得多像，在于这几个人掌握的信息不再相同。

09 · 架构

# 可见性在服务端收口，前端拿不到

| | | | |
|---|---|---|---|
| 客户端 | 浏览器 Web | 移动端 Web | |
| 前端层 | app/page.tsx | Next.js App Router · SSE 流式 | |
| 接口层 | POST /api/chat | GET /api/characters | POST /api/import-skill |
| **核心层** | **圆桌调度器 → 可见性过滤器 → 模型调用 → 输出装配** | | |
| 模型层 | 智谱 GLM-4-Flash （默认） | BYOK · 任意 OpenAI 兼容接口 | |
| 部署层 | 阿里云香港 · podman | nginx 反代 · HTTPS | |

每条发言带「public / 仅某人可见」标记；组装 prompt 之前按可见性裁剪历史，消息不会进入不可见者的上下文。

10 · 边界

# 现在还不好用的地方

这些不打算藏——评委自己发现，反而更难看。

01 **新颖度是个近似**

用字符 2-gram 重叠率估算「说了多少新东西」。它不理解语义：用新词讲旧观点会被判成新的，反过来也会误判。便宜、即时，但不准。

02 **主持人收尾看模型脸色**

第五个机制完全靠提示词约束模型。模型状态不好时，收尾会退化成一次平庸的总结，而不是拆穿。

03 **悄悄话一次只能对一个人**

同时告知多人、形成临时小圈子，还没做。这是下一步最想要的能力。

《测试说明》里逐条记录了这些边界，连同触发条件。

在线体验

# outgate.chat

现在就可以打开。免费、无需注册，手机上也能用。

选择一个议题，请两三位入席，然后私下对其中一个人说点什么。

扫码直接进

冯思涵 · 张耀羽　哈尔滨金融学院

指导教师：胡芳驰 · 霍镜宇　　作品编号： 375993